

Задание: Прогнозирование отказов оборудования на производственной линии

Крупная промышленная компания (Bosch) имеет сложную производственную линию, состоящую из тысяч сенсоров и узлов оборудования. Задача - по показаниям датчиков на ранних этапах производственного цикла предсказать, приведёт ли текущая партия продукции к дефекту или отказу. Раннее обнаружение брака позволяет снизить затраты на переработку и повысить качество выпускаемой продукции.

Предметка: производственная линия включает три основных этапа. Если модель сможет с высокой точностью предсказывать брак на ранних стадиях, операторы смогут останавливать процесс и корректировать параметры до того, как дефектная продукция будет произведена.

Данные: Bosch Production Line Performance, промышленные данные, использовавшиеся в соревновании на Kaggle: [Kaggle - Bosch Production Line Performance](#) . Обучающая выборка содержит несколько сотен тысяч записей (рекомендуется использовать выборку для ускорения вычислений)

Целевая переменная (Response) - бинарный признак: 0 - партия прошла без дефектов 1 - партия привела к дефекту/отказу

Входные признаки:

- Показания датчиков на разных этапах производственного цикла
- Три стадии производства (Stage 1, Stage 2, Stage 3)
- Анонимизированные числовые и категориальные характеристики

Задание 1. Исследовательский анализ данных (EDA)

1. Загрузите данные и изучите их структуру (используйте Pandas)
2. Проведите анализ пропущенных значений - визуализируйте долю пропусков по признакам
3. Определите степень дисбаланса классов (постройте countplot целевой переменной)
4. Для сокращения размерности выберите 10–20 признаков с наибольшей корреляцией к целевой переменной (или используйте PCA для демонстрации)

Задание 2. Построение модели логистической регрессии

1. Разделите данные на обучающую и тестовую выборки (80/20) с сохранением распределения классов (stratify)
2. Выполните масштабирование признаков (StandardScaler) - важно для логистической регрессии
3. Обучите модель **логистической регрессии** с настройкой гиперпараметров:
 - C - коэффициент регуляризации (подберите по GridSearchCV)
 - class_weight='balanced' для учёта дисбаланса классов
1. Оцените качество модели на тестовой выборке с использованием метрик:
 - **Accuracy** - общая точность
 - **Precision** - точность предсказания дефектов
 - **Recall** - полнота (способность находить реальные дефекты)
 - **F1-score** - гармоническое среднее
 - **AUC-ROC** - площадь под ROC-кривой

Задание 3. Анализ и интерпретация

1. Постройте матрицу ошибок (confusion matrix) и проанализируйте, какие ошибки критичнее для производства: ложноположительные или ложноотрицательные?
2. Извлеките и визуализируйте 10 наиболее значимых признаков по модулю коэффициентов модели
3. Сделайте выводы о практической применимости модели:
 - Достаточна ли полнота для раннего обнаружения дефектов?
 - Какое количество ложных срабатываний допустимо в реальном производстве?

Рекомендуемый стек

Назначение	Библиотеки
Обработка данных	Pandas, NumPy
Визуализация	Matplotlib, Seaborn
Предобработка, масштабирование, отбор признаков	Scikit-learn (StandardScaler, PCA, SelectKBest)
Моделирование	Scikit-learn (LogisticRegression, GridSearchCV)
Балансировка классов	imbalanced-learn (SMOTE)
Среда разработки	Jupyter Notebook / Google Colab